

Cours de Théorie des Langages

Partie 1

Anne Berry

11 septembre 2015

Anne.BERRY@univ-bpclermont.fr
[http ://www.isima.fr/ berry/](http://www.isima.fr/berry/)

- Site du cours sur l'ENT (transparents, feuilles d'exercices)
- Cours en 2 parties
 - Partie 1 (Anne Berry) : septembre 2014 - octobre
 - Partie 2 (Olivier Raynaud) : novembre - décembre
- Modalités de contrôle des connaissances : 1e session :
2 contrôles continus (un à la fin de chaque partie)
2e session : examen écrit (2 heures)

- Introduction à la théorie des langages
- Machines à états finis, grammaires, expressions régulières
- Etude des langages rationnels


- Introduction to Automata Theory, Languages, and Computation
John E. Hopcroft, Rajeev Motwani, Jeffrey D. Ullman
- Introduction to Computer Theory
Daniel I. A. Cohen
- Wikipedia

Théorie des langages : informatique fondamentale

Révolutions théoriques du 20e siècle + heureuses coïncidences !

- Georg Cantor (1845-1918) (Allemand)
- David Hilbert (1862-1943) (Allemand)
- Kurt Gödel (1906-1978) (Autrichien, US)
- Alonzo Church (1903-1995) (US)
- Alan Turing (1903-1995) (Anglais)
- John Von Neumann (1903-1957) (Hongrois, US)
- Noam Chomsky (1928-) (US)
- John Backus (1924-2007) (US)
- Peter Naur (1928-) (Danois)

Georg Cantor (1845-1918) (Allemand)



Théorie des ensembles
Paradoxes sur l'infini

Bertrand Russel (1872 – 1970) (Anglais)



Philosophe et logicien

Paradoxe (antinomie) de Russel (1902) :


l'ensemble des ensembles qui ne se contiennent pas eux-mêmes....

David Hilbert (1862-1943) (Allemand)



Technique de preuve, algorithme de preuve.

Kurt Gödel (1906-1978) (Autrichien, US)




Théorème d'incomplétude (1931).

Alonzo Church (1903-1995) (US)




Existence de problème non résolubles par un algorithme.

Alan Turing (1903-1995) (Anglais)



Machine algorithmique universelle.
Programme de décodage (guerre).

John Von Neumann (1903-1957) (Hongrois, US)



De la calculette à l'ordinateur : concept du programme stocké.
Avant :

- Blaise Pascal (1623-1662)
- Ada Lovelace (1815-1852)
- Charles Babbage (1791-1871)

Noam Chomsky (1928-) (US)



Linguiste, formalisation des langages.

John Backus (1924-2007) (US) Peter Naur (1928-) (Danois)



Langages de haut niveau, Algol 60

- ① Langages
- ② Grammaires
- ③ Langages rationnels
- ④ Automates d'états finis

2. Langages

- 2.1. Définition d'un langage
- 2.2. Définitions inductives
- 2.3. Définitions sur les langages
- 2.4. Opérations sur les langages

2.1. Définition d'un langage

Un langage est un ensemble de mots, qui peut être défini :

- En **extension** : liste exhaustive de tous les mots du langage.

Exemple : un dictionnaire

- En **compréhension** : on commence une énumération.

Exemple : $L = \{ab, aabb, aaabbb, \dots\}$

- En **intension** : on se donne des 'règles'

Exemple : Tous les mots formés de 'a' et de 'b' qui comportent autant d'occurrences de 'a' que d'occurrences de 'b' et dont tous les 'a' sont en début de mot.

- **Inductivement.**

→ Outils de définitions compacts des langages.

2.2. Définitions inductives

Les définitions inductives (en anglais : recursive definitions)

Idée : on procède en 3 étapes

- ❶ On se donne une **base** d'objets appartenant à l'ensemble que l'on veut définir
- ❷ On se donne des **règles** pour construire d'autres objets de l'ensemble à partir d'objets de la base ou d'objets déjà construits.
- ❸ On déclare que les seuls objets de l'ensemble sont ceux construits en **appliquant** un nombre **fini** de fois les règles.

2.2. Définitions inductives

- on n'exige pas que la base soit minimale
- souvent on donne une définition inductive sous la forme
base+règles

2.2. Définitions inductives

Exemple :

Définissons l'ensemble PAIR des entiers pairs positifs

- ❶ Base : 2 appartient à PAIR
- ❷ Règle : Si x est dans PAIR, alors $x+2$ est dans PAIR

Pour montrer qu'un nombre est dans PAIR, on exhibera une suite d'application des règles.

2.2. Définitions inductives

La définition inductive d'un ensemble n'est pas unique.

Exemple On peut définir PAIR par :

- ❶ Base : 2 est dans PAIR
- ❷ Règle : si x et y sont dans PAIR, alors $x+y$ est dans PAIR

2.2. Définitions inductives

Avantage de la 2e définition : les preuves qu'un nombre appartient à PAIR sont plus courtes.

Définition

Soit U un univers et $B \subset U$ une base, soit Ω une famille d'opérations sur U .

On appelle **fermeture inductive** de B par Ω la partie E de U définie par :

- *initialisation* : $B \subset E$
- *construction* : $\forall f \in \Omega$ et $\forall x_1, x_2, \dots, x_n \in E$, si n est l'arité de f , si $x = f(x_1, x_2, \dots, x_n)$ est défini, alors $x \in E$
- *fermeture* : E est la plus petite partie de U qui contienne B et qui soit stable par Ω .

2.2. Définitions inductives

Principe pour décrire des langages par une **grammaire**
(procédé formel de construction inductive du langage)
sous la forme d'un axiome (la base) et d'un ensemble de règles de production.

2.3. Définitions sur les langages

Définition

Un alphabet Σ est un ensemble fini de caractères.

Exemple : $\Sigma = \{a, b\}$

Définition

- Un **mot** (appelé aussi une **chaîne**) ω sur Σ est une suite finie de symboles de Σ juxtaposés.
- Sa **longueur** (= nombre de caractères) est notée $|\omega|$.
- $|\omega|_a$ dénote le nombre d'occurrences de la lettre ' a ' $\in \Sigma$ dans le mot ω .

*Exemple : $\Sigma = \{a, b\}$, $\omega = aabaa$ est un mot sur Σ ;
 $|\omega| = 5$, $|\omega|_a = 4$.*

2.3. Définitions sur les langages

Le **mot vide**, ne contenant aucun symbole, est noté ϵ .

$$|\epsilon|=0.$$

ϵ peut être un mot d'un langage, mais n'est pas une lettre de l'alphabet.

2.3. Définitions sur les langages

Définition

Si α et β sont 2 mots sur Σ , on appelle **concaténation** de α et β le mot $\alpha\beta$,

noté $\alpha \circ \beta$, $\alpha \bullet \beta$, $\alpha.\beta$, $\alpha\beta$

Exemple :

$\alpha = ab$, $\beta = cd$

$\alpha \bullet \beta = abcd$

2.3. Définitions sur les langages

Concaténation avec le mot vide :

$$\alpha \bullet \epsilon = \epsilon \bullet \alpha = \alpha.$$

On notera a^n la concaténation de n occurrences de a (n un nombre fini).

a^0 dénotera le mot vide ϵ .

2.3. Définitions sur les langages

Définition

On appelle **facteur** ou **sous-mot** d'un mot ω un mot α tel qu'il existe 2 mots β et γ , avec $\omega = \beta\alpha\gamma$.

Exemple :

$\omega = abccdx$

cc est un facteur de ω .

2.3. Définitions sur les langages

Définition

Si $\omega = \alpha.\beta$

on dira que α est un **préfixe** de ω , et que β est un **suffixe** de ω .

Exemple :

$\omega = abccdx$

abc est un préfixe (propre).

abccdx est préfixe (mais pas propre).

dx est suffixe.

2.3. Définitions sur les langages

Définition

Soit Σ un alphabet, on appelle **fermeture de Kleene** de Σ , noté Σ^* , l'ensemble défini inductivement de la façon suivante :

base : tous les caractères de Σ ainsi que le mot vide ϵ sont dans Σ^ .*

règle : si x et y sont dans Σ^ , alors xy est dans Σ^* .*

Σ^* est l'ensemble des mots sur Σ , de longueur finie, plus le mot vide ϵ .

2.3. Définitions sur les langages

Définition

Soit Σ un alphabet, Σ^+ est l'ensemble défini inductivement de la façon suivante :

base : tous les caractères de Σ sont dans Σ^+ .

règle : si x et y sont dans Σ^+ , alors xy est dans Σ^+ .

Σ^+ est l'ensemble des mots sur Σ , de longueur finie.

2.3. Définitions sur les langages

Définition

On appelle **langage** (souvent noté L) sur un alphabet Σ un sous-ensemble de Σ^* .

2.3. Définitions sur les langages

Définition

$\overline{L_1}$ est l'ensemble des mots de Σ^* qui ne sont pas dans L_1 .
 $\overline{L_1}$ s'appelle le **complémentaire** de L_1 .

2.4. Opérations sur les langages

\cup, \cap

Soient L_1 et L_2 2 langages sur l'alphabet Σ

$$L_1 \cup L_2 = \{\omega \mid \omega \in L_1 \text{ ou } \omega \in L_2\}$$

$$L_1 \cap L_2 = \{\omega \mid \omega \in L_1 \text{ et } \omega \in L_2\}$$

2.4. Opérations sur les langages

Produit de 2 langages

Soient L_1 un langage sur l'alphabet Σ_1

et L_2 un langage sur l'alphabet Σ_2

$$L_1 \bullet L_2 = \{\omega_1 \omega_2 \in (\Sigma_1 \cup \Sigma_2)^*, \omega_1 \in L_1 \text{ et } \omega_2 \in L_2\}$$

2.4. Opérations sur les langages

Fermeture de Kleene d'un langage :

$$1 - L^0 = \{\epsilon\}$$

$$2 - L^n = LL^{n-1}, \forall n \geq 1$$

$$3 - L^* = \bigcup L^n, n \geq 0$$

$$4 - L^+ = \bigcup L^n, n > 0$$

2.5. L'ambiguïté

Définition

*Une phrase **ambigüe** est une phrase à laquelle on peut attribuer plusieurs sens.*

En informatique : **conflit**.

Définition

*Une **interprétation** d'une phrase ambigüe est un sens que l'on attribue à cette phrase.*

Exemple 1 : C'est la voiture de l'étudiant qui a coulé une bielle.

*Exemple 2 : L'expression $2 + 3 * 4$ est ambigüe :*

- Interprétation 1 : $(2+3)*4$ (le résultat est 20)
- Interprétation 2 : $2+(3*4)$ (le résultat est 14)

2.5. Une hiérarchie de langages

Chomsky a défini une hiérarchie des langages (la hiérarchie de Chomsky) en 4 grandes classes.

- Type 0 : Langages récursivement énumérables.
- Type 1 : Langages contextuels.
- Type 2 : Langages algébriques (context-free).
- Type 3 : Langages rationnels (réguliers).

Propriété

On a : $Type\ 3 \subsetneq Type\ 2 \subsetneq Type\ 1 \subsetneq Type\ 0$

Dans cette 1^{re} partie, nous étudierons les langages de type 3 (les plus simples).